

**DCA**

Departamento de Engenharia de  
Computação e Automação  
Industrial



Faculdade de Engenharia  
Elétrica e de Computação



Unicamp



# Otimização Evolutiva Multiobjetivo

Guilherme P. Coelho e Fernando J. Von Zuben

**Tópico 10 – IA707 – Computação Evolutiva**

# Conteúdo

---

- ▶ Conceitos Básicos;
- ▶ Algoritmos Clássicos vs. Algoritmos Evolutivos;
- ▶ Casos de Estudo;
- ▶ Tendências e Aplicações;
- ▶ Referências.

# Conteúdo

- ▶ **Conceitos Básicos:**
  - ▶ Definição;
  - ▶ Espaço de Variáveis e Espaço de Objetivos;
  - ▶ Conjunto e Fronteira de Pareto;
  - ▶ Dominância;
  - ▶ Abordagens para Resolução de Problemas MO;
- ▶ Algoritmos Clássicos vs. Algoritmos Evolutivos;
- ▶ Casos de Estudo;
- ▶ Tendências e Aplicações;
- ▶ Referências.

# Conceitos Básicos

## Problemas de Otimização Multiobjetivo (OMO)

- ▶ São problemas de otimização caracterizados pela existência de mais de um critério a ser otimizado;
- ▶ Estes critérios são, na maioria das vezes, conflitantes entre si.
- ▶ Formalmente (minimização):

$$\begin{array}{ll} \text{Minimizar} & \mathbf{F}(\mathbf{x}) = \{F_1(\mathbf{x}), F_2(\mathbf{x}), \dots, F_M(\mathbf{x})\} \\ \text{Sujeito a:} & g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, J \\ & h_k(\mathbf{x}) = 0 \quad k = 1, 2, \dots, K \\ & x_i^L \leq x_i \leq x_i^U \quad i = 1, 2, \dots, n \\ & x_i \in \mathbb{R}^n \end{array}$$

# Conceitos Básicos

## Exemplo – Objetivos Conflitantes

- ▶ Construção de um automóvel → determinar espessura e material das chapas metálicas para que se tenha:
  - ▶ Menor custo de produção;
  - ▶ Máxima resistência a colisões;
  - ▶ Economia de combustível (menor peso);



vs.




vs.



# Conceitos Básicos

# Otimização Mono-Objetivo

- ▶ Ótimo corresponde às soluções extremas (mínimas ou máximas) da função-objetivo do problema em questão;



# Conceitos Básicos

## Otimização Multiobjetivo

Impossível simplesmente adotar a solução extrema de um dos objetivos quando os demais critérios também são relevantes ao problema




Soluções em extremos de um único objetivo exigem um **compromisso** nos demais objetivos (cenários conflitantes)

**Ótimo deste tipo de problema:** conjunto de soluções que correspondem a compromissos (*trade-offs*) diferentes entre os objetivos

# Conceitos Básicos

## Espaço de Variáveis e Espaço de Objetivos

- ▶ Problemas de Otimização Multiobjetivo:
  - ▶ Exigem que se trabalhe com **dois espaços** simultaneamente;




Existe um **mapeamento** de todas as soluções (pontos) do **espaço de variáveis** para o **espaço de objetivos** do problema.




# Conceitos Básicos

## Espaço de Variáveis e Espaço de Objetivos

- ▶ Soluções de problemas de OMO:
  - ▶ Recebem nomes diferentes, quando representadas nos espaços de variáveis e de objetivos.



Conjunto de Pareto



Fronteira de Pareto

# Conceitos Básicos

## Conjunto e Fronteira de Pareto

- ▶ Uma dada solução  $\mathbf{x}^*$  é dita pertencer ao **conjunto (fronteira) de Pareto** se não existir nenhuma outra solução  $\mathbf{x}$  **factível**, capaz de melhorar um dos objetivos do problema (em relação a  $\mathbf{x}^*$ ) sem simultaneamente piorar pelo menos um dos demais;




- ▶ Todas as soluções pertencentes ao **conjunto (fronteira) de Pareto** são ditas **não-dominadas**;

**Dominância:** critério que permite comparar a qualidade de duas soluções de problemas de OMO.

# Conceitos Básicos

## Dominância


- ▶ Uma dada solução  $\mathbf{u}$  domina uma solução  $\mathbf{v}$  ( $\mathbf{u} \preceq \mathbf{v}$ ) se e somente se:
  - ▶  $\mathbf{u}$  é melhor ou igual a  $\mathbf{v}$  em todos os objetivos do problema;
  - ▶ Existe pelo menos um objetivo em que  $\mathbf{u}$  é estritamente melhor que  $\mathbf{v}$ .



- - Soluções não-dominadas
- - Soluções dominadas

# Conceitos Básicos

## Fronteira de Pareto



# Conceitos Básicos

## Formalização do Conceito de “Ótimo”

- ▶ Ótimo de um problema multiobjetivo no espaço de variáveis:  
*conjunto ótimo de Pareto ( $P^*$ ):*

$$P^* = \{ \mathbf{x} \in \Omega \mid \nexists \mathbf{x}' \in \Omega: F(\mathbf{x}') \leq F(\mathbf{x}) \}$$


- ▶ Mapeamento do conjunto ótimo de Pareto no espaço de objetivos:  
*fronteira de Pareto ( $PF^*$ ):*

$$PF^* = \{ \mathbf{u} = F(\mathbf{x}) \mid \mathbf{x} \in P^* \}$$

# Conceitos Básicos

## Abordagens para Resolução de Problemas MO

- ▶ Quando os múltiplos objetivos são conflitantes → múltiplas soluções;
- ▶ Cada solução corresponde a um possível compromisso ótimo entre os objetivos;



Como obter a solução que melhor se ajusta ao seu problema?

**Busca + Decisão**

# Conceitos Básicos

## Abordagens para Resolução de Problemas MO

- ▶ Inserção de preferências *a posteriori*: busca-se encontrar o maior número de soluções possível, para só depois selecionar a mais adequada ao problema (**busca** → **decisão**);
- ▶ Inserção de preferências *a priori*: já se tem de antemão alguma informação sobre o tipo de solução mais adequada ao problema, então a busca é direcionada para encontrar este tipo de soluções (**decisão** → **busca**);
- ▶ Inserção progressiva de preferências: é feito um direcionamento da busca, durante sua execução, para regiões que contenham soluções mais adequadas (**decisão** ↔ **busca**).

# Conceitos Básicos


## Requisitos para um algoritmo de otimização MO

- ▶ Preservar as soluções não-dominadas encontradas ao longo da busca;
- ▶ Progredir continuamente em direção à Fronteira de Pareto;
- ▶ Manter a diversidade de soluções tanto no espaço de objetivos (fronteira de Pareto) quanto no espaço de variáveis;
- ▶ Retornar ao usuário uma quantidade suficiente (mas ao mesmo tempo limitada) de soluções.



# Conceitos Básicos


## Requisitos para um algoritmo de otimização MO



- Modificam-se as soluções **no espaço de variáveis** para que elas se aproximem da fronteira de Pareto **no espaço de objetivos**.

# Conceitos Básicos

## Requisitos para um algoritmo de otimização MO



- **Aproximação** e **Cobertura** da fronteira de Pareto.

# Conceitos Básicos

## Manutenção de diversidade em otimização MO

- ▶ Poucas ferramentas se preocupam com manutenção de diversidade no espaço de variáveis;
- ▶ Também é importante:

Melhor exploração do espaço de variáveis tende a levar a um **tratamento mais eficiente de problemas multiobjetivo multimodais**

Manutenção de diversidade no espaço de variáveis tende a levar à obtenção de um **conjunto de Pareto mais completo**

# Conteúdo

---

- ▶ Conceitos Básicos;
- ▶ Algoritmos Clássicos vs. Algoritmos Evolutivos:
  - ▶ Algoritmos Clássicos;
  - ▶ Vantagens das Abordagens Evolutivas
  - ▶ NSGA-II;
  - ▶ SPEA2;
  - ▶ Outras Propostas;
- ▶ Casos de Estudo;
- ▶ Tendências e Aplicações;
- ▶ Referências.

# Conceitos Básicos

## Algoritmos Clássicos vs. Algoritmos Evolutivos

### ▶ Algoritmos “Clássicos”:

- ▶ Abordagens não-evolutivas (não são meta-heurísticas) geralmente aplicadas em pesquisa operacional;
- ▶ Geralmente modificam o problema de otimização multiobjetivo e aplicam ferramentas tradicionais de otimização;

### ▶ Algoritmos Evolutivos:



- ▶ São mais flexíveis;
- ▶ Vêm sendo muito utilizados para tratar problemas de otimização multiobjetivo.

# Métodos Clássicos

## Soma Ponderada (Combinação Linear)

- Converte o problema ponderando os objetivos;
- A soma dos pesos deve ser 1;
- É preciso escalonar todos os objetivos para a mesma faixa;

$$\begin{aligned}
 \text{Minimizar } F(\mathbf{x}) &= \sum_{m=1}^M w_m \cdot F_m(\mathbf{x}) \\
 \text{Sujeito a: } &g_j(\mathbf{x}) \geq 0 & j = 1, 2, \dots, J \\
 &h_k(\mathbf{x}) = 0 & k = 1, 2, \dots, K \\
 &x_i^L \leq x_i \leq x_i^U & i = 1, 2, \dots, n
 \end{aligned}$$




# Métodos Clássicos

## $\varepsilon$ -Restrição

- ▶ Mantém apenas um dos objetivos originais como novo objetivo e converte os demais em restrições de desigualdade;
- ▶ Elimina o problema com espaços de objetivos não-convexos;
- ▶ Deve-se determinar  $\varepsilon$  de forma a gerar um problema factível;

$$\begin{array}{ll}
 \text{Minimizar} & F_{\mu}(\mathbf{x}) \\
 \text{Sujeito a:} & F_m(\mathbf{x}) \leq \varepsilon_m \quad m = 1, 2, \dots, M \text{ e } m \neq \mu \\
 & g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, J \\
 & h_k(\mathbf{x}) = 0 \quad k = 1, 2, \dots, K \\
 & x_i^L \leq x_i \leq x_i^U \quad i = 1, 2, \dots, n
 \end{array}$$



# Métodos Clássicos

## Outras Técnicas

- ▶ Inserção de preferências *a posteriori*:
  - ▶ Combinação Linear;
  - ▶  $\varepsilon$  -restrição; ...
- ▶ Inserção de preferências *a priori*:
  - ▶ Método de Critério Global;
  - ▶ *Goal Programming*;
  - ▶ Lexicográfico; ...
- ▶ Inserção progressiva de preferências:
  - ▶ Sequential Multiobjective Problem Solving – SEMOPS; ...



# Métodos Clássicos

## Principais Problemas

- ▶ Geralmente encontram uma única solução a cada execução: precisam ser executados  $N$  vezes, com conjuntos distintos de parâmetros, para obterem  $N$  soluções diferentes;
- ▶ Nem sempre conseguem uma cobertura uniforme da fronteira;
- ▶ Nem todas as possíveis soluções podem ser encontradas por alguns métodos (ex.: regiões não-convexas);
- ▶ Geralmente requerem algum conhecimento prévio sobre o problema (ex.: definir adequadamente os valores de  $\varepsilon$  para o método de  $\varepsilon$ -restrição).

# Algoritmos Evolutivos

## Vantagens


- ▶ Algoritmos populacionais → trabalham simultaneamente com múltiplas soluções;
- ▶ Com múltiplas soluções → possibilidade de manutenção de múltiplos indivíduos diversos (soluções) na população;
- ▶ As múltiplas soluções podem ser obtidas em uma única execução;
- ▶ Tendem a ser menos susceptíveis à forma da Fronteira de Pareto e a eventuais descontinuidades.

**Também apresentam desvantagens!**

# Algoritmos Evolutivos

## Modificações necessárias para OMO – *Fitness*

- ▶ Algoritmos Evolutivos Mono-Objetivo: um valor de função-objetivo;
- ▶ Algoritmos Evolutivos Multiobjetivo (MOEA): vetor de funções-objetivo;



É preciso algum processamento adicional para tratar os vetores de *fitness*!

- ▶ *Fitness Assignment*: SPEA2 (Zitzler et al., 2001);
- ▶ Ordenação por critério de não-dominância: NSGA-II (Deb et al., 2000);

# Algoritmos Evolutivos

## Modificações necessárias para OMO – *Diversidade*

- ▶ Em algoritmos evolutivos mono-objetivo:
  - ▶ Manutenção de diversidade no espaço de variáveis → multimodalidade;
- ▶ Em algoritmos evolutivos multiobjetivo (MOEAs):
  - ▶ Manutenção de diversidade no **espaço de variáveis**:
    - ▶ Multimodalidade;
    - ▶ Melhor cobertura do conjunto de Pareto;
  - ▶ Manutenção de diversidade no **espaço de objetivos**:
    - ▶ Melhor cobertura da fronteira de Pareto.

# Algoritmos Evolutivos


## Nondominated Sorting Genetic Algorithm II: NSGA-II (Deb et al. 2000)

- ▶ Evolução do algoritmo NSGA, proposto por Srinivas & Deb em 1995;
  - ▶ Algoritmo Genético;
  - ▶ Elitista;
  - ▶ Utiliza **ordenação** dos indivíduos **por critério de não-dominância**;
  - ▶ Manutenção de diversidade: **crowding distance** (espaço de objetivos).

# Algoritmos Evolutivos

## NSGA-II: Ordenação por Não-Dominância


- ▶ É uma forma de atribuir uma nota a um indivíduo  $\rightarrow$  “*fitness*”;
- ▶ Divide os indivíduos em classes, de acordo com a não-dominância:
  - ▶ Indivíduos não dominados  $\rightarrow$  classe 1;
  - ▶ Indivíduos dominados apenas pelos indivíduos da classe 1  $\rightarrow$  classe 2;
  - ▶ Indivíduos dominados apenas pelos indivíduos das classes 1 e 2  $\rightarrow$  classe 3;
  - ▶ ...



# Algoritmos Evolutivos

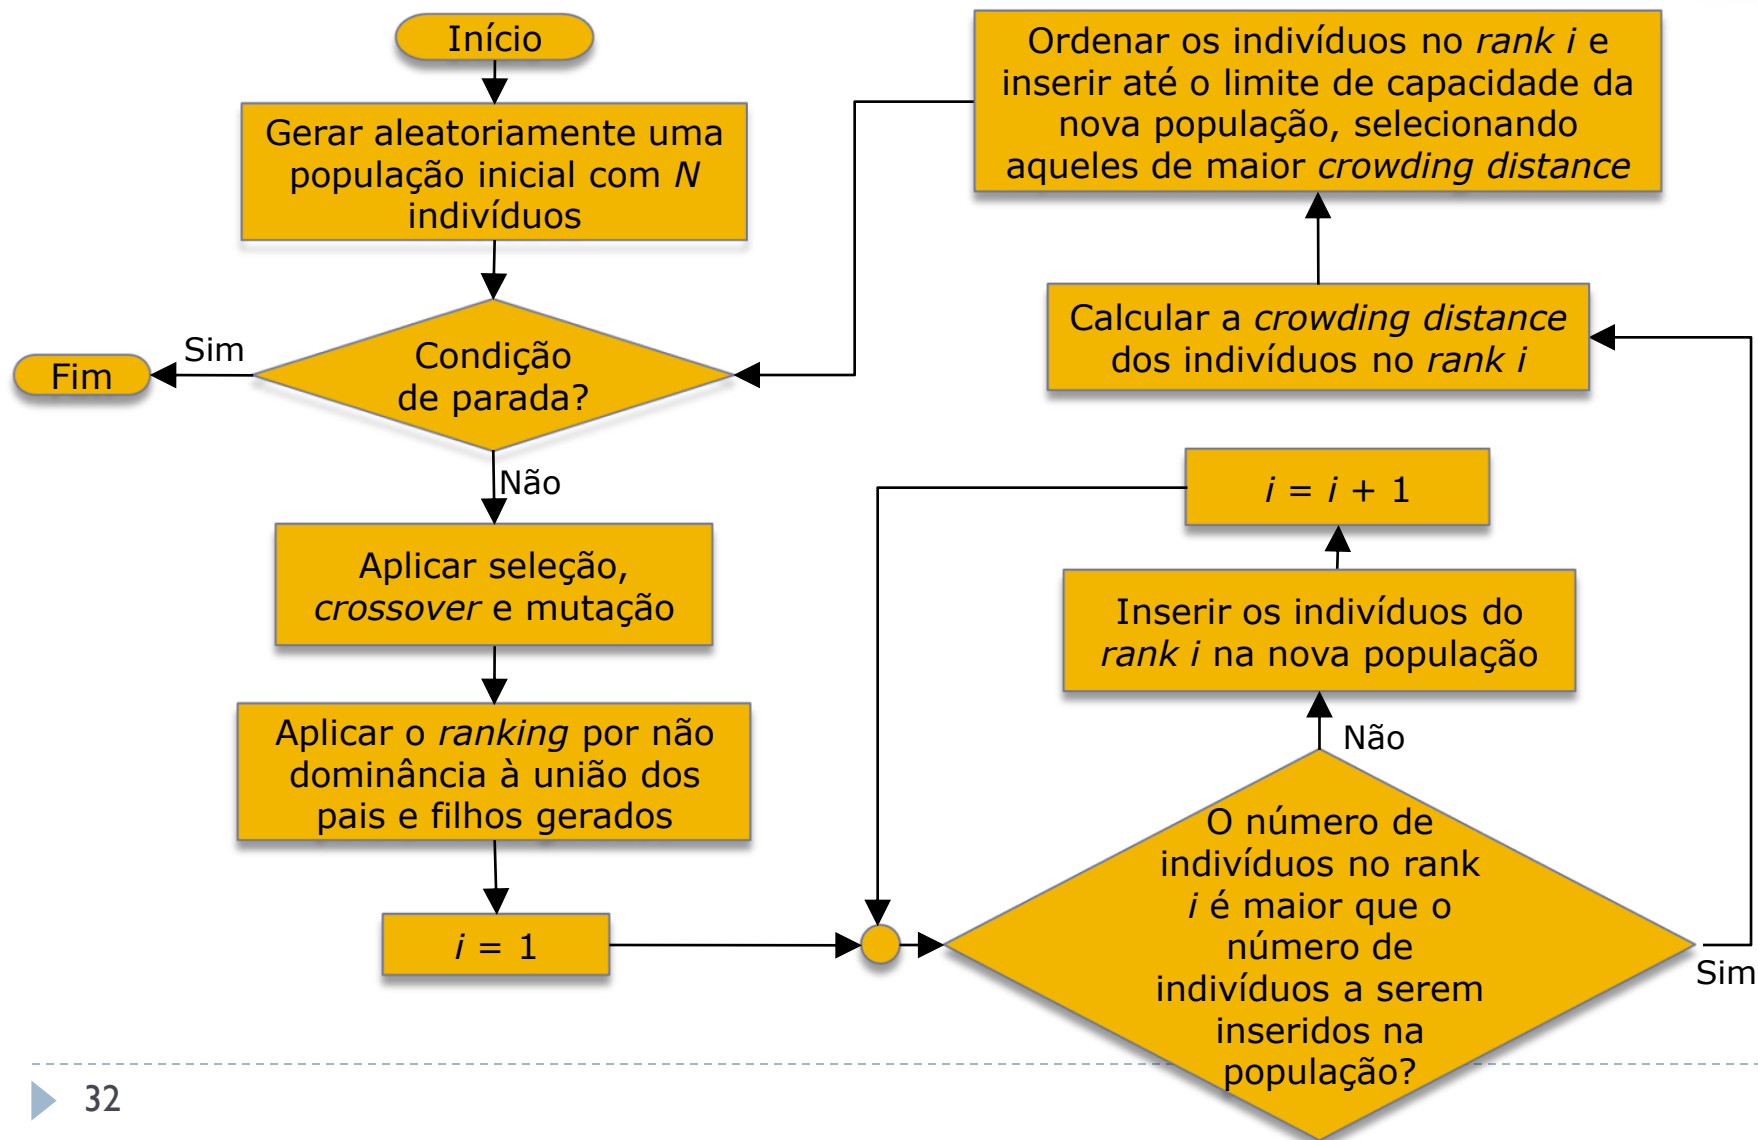
## NSGA-II: Diversidade por Crowding-Distance

- ▶ A medida de crowding distance busca estimar a vizinhança de cada indivíduo no espaço de objetivos do problema;
- ▶ Corresponde ao volume do hipercubo formado pelas soluções imediatamente anteriores e posteriores para cada objetivo.



- ▶ **Métrica Custosa:** exige a ordenação dos indivíduos para cada objetivo.

# Algoritmos Evolutivos – NSGA-II





# Algoritmos Evolutivos

## NSGA-II: Tratamento de Restrições

- ▶ Problemas com restrições são tratados com uma simples modificação na definição de dominância:



### Dominância Restrita

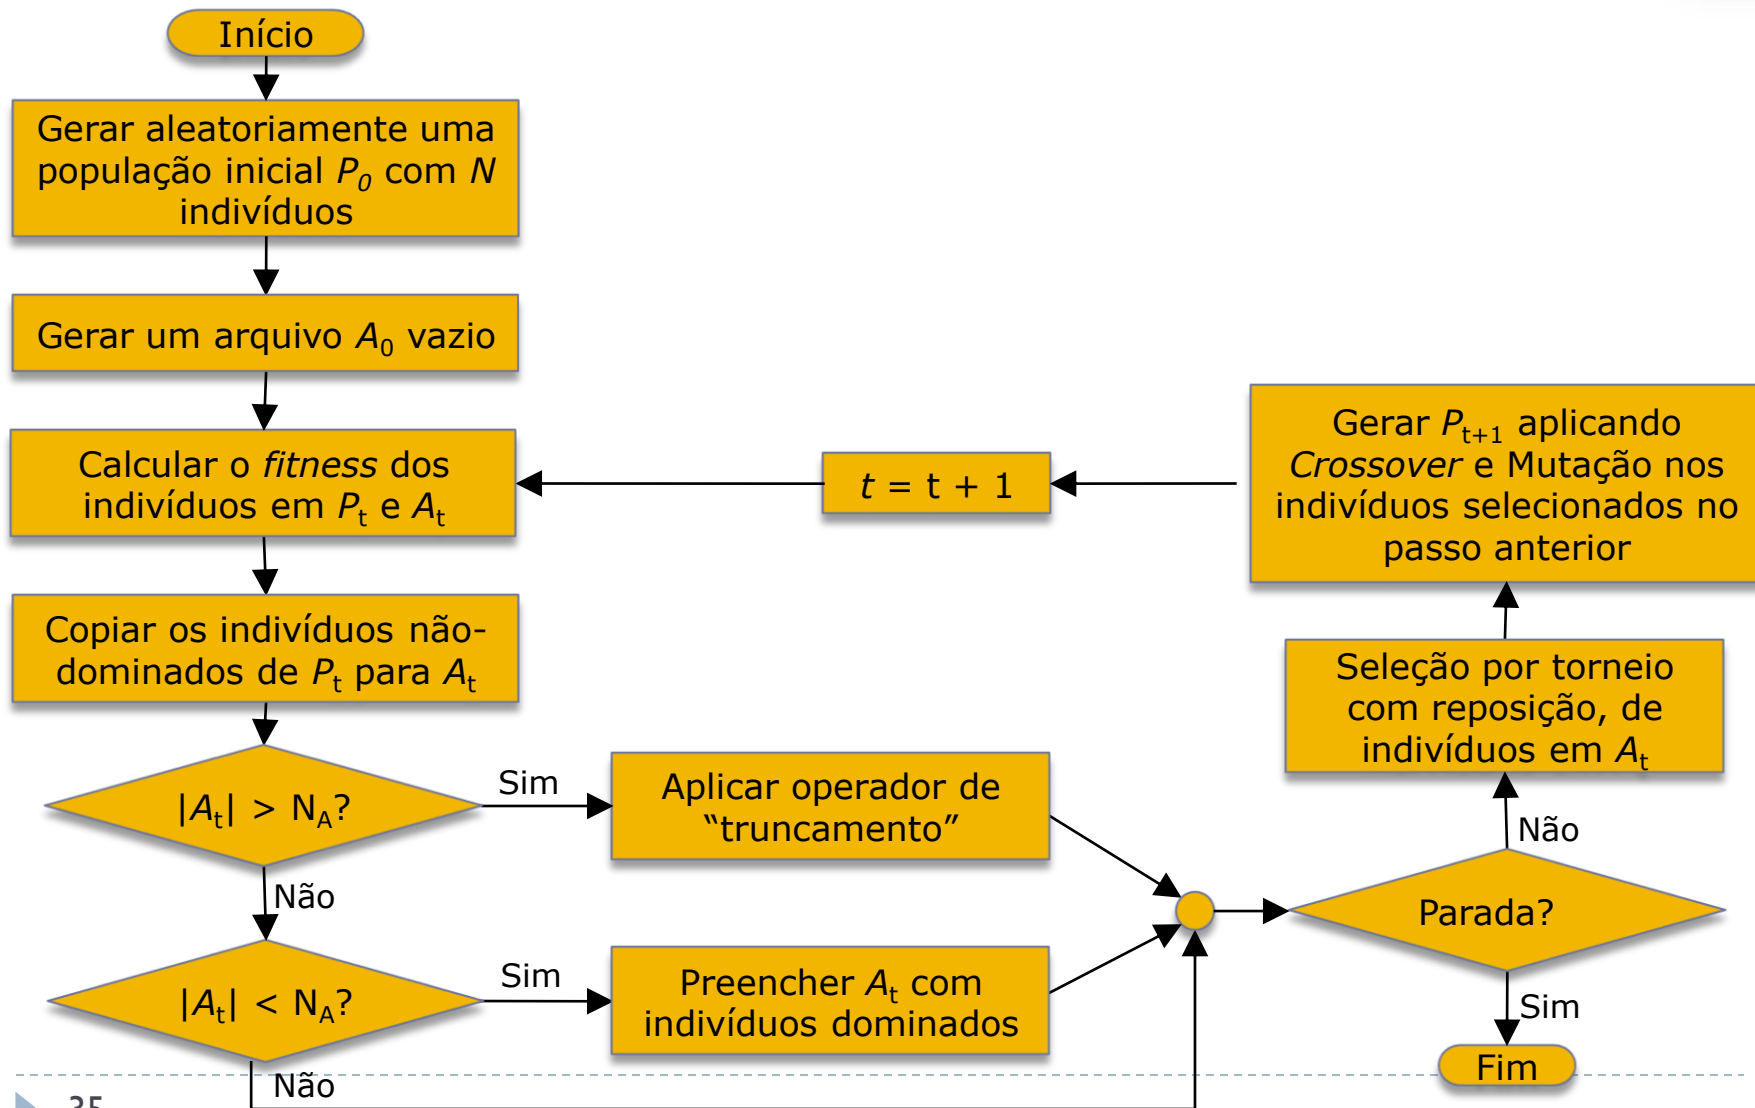
- ▶ Dadas duas soluções  $\mathbf{u}$  e  $\mathbf{v}$ , diz-se que  $\mathbf{u}$  domina  $\mathbf{v}$  com restrições se:
  - ▶  $\mathbf{u}$  é factível e  $\mathbf{v}$  não é factível;
  - ▶ Ambas as soluções são infactíveis, mas  $\mathbf{u}$  viola menos as restrições que  $\mathbf{v}$ ;
  - ▶ Ambas as soluções são factíveis e  $\mathbf{u}$  domina  $\mathbf{v}$ .

# Algoritmos Evolutivos

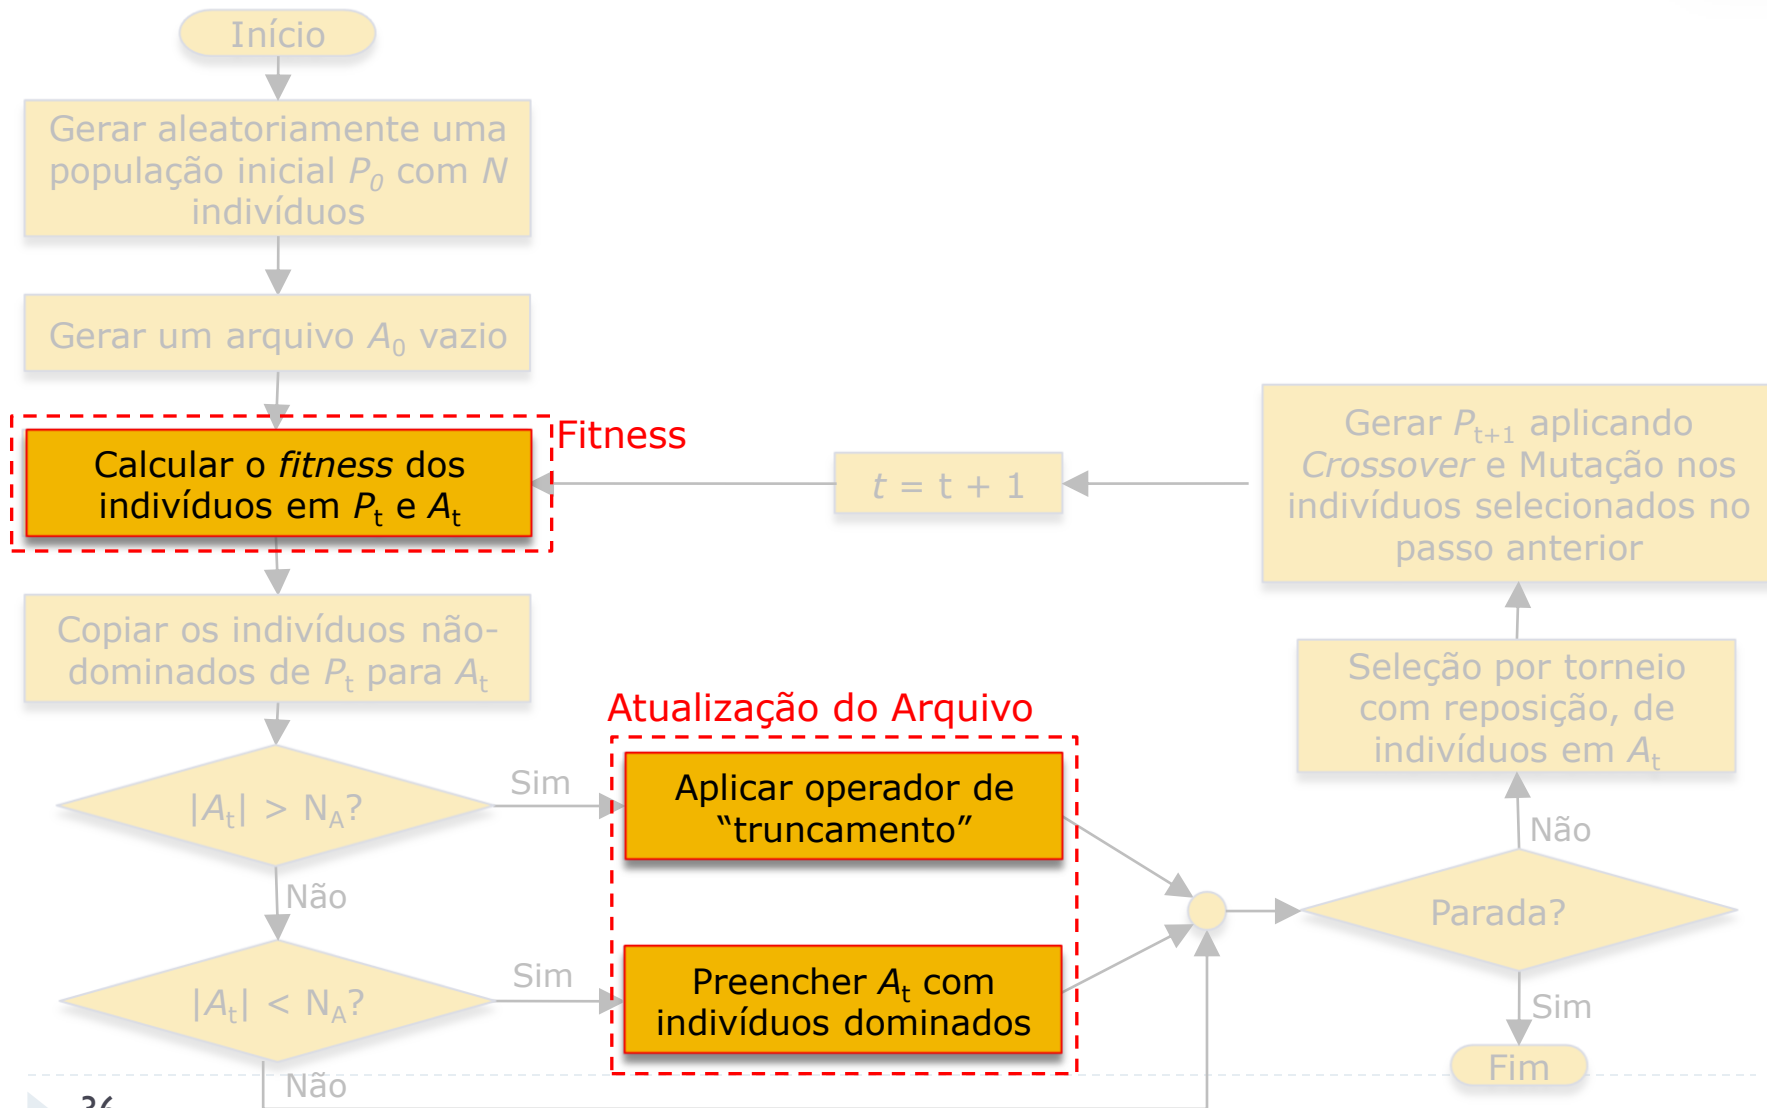
## Strength Pareto Evolutionary Algorithm II: SPEA2 (Zitzler et al. 2001)

- ▶ Evolução do algoritmo SPEA, proposto por Zitzler & Thiele em 1999;
  - ▶ Utiliza mecanismo de **atribuição de fitness** aos indivíduos;
  - ▶ Mantém duas populações → **indivíduos na busca** e **arquivo de soluções não-dominadas**, ambas de tamanho fixo;
  - ▶ Direciona a busca baseando-se na **densidade de soluções** na vizinhança de cada indivíduo.

# Algoritmos Evolutivos – SPEA2



# Algoritmos Evolutivos – SPEA2



# Algoritmos Evolutivos

## SPEA2: Cálculo do *Fitness*

- ▶ Força  $S(i)$  do indivíduo  $i$ : número de indivíduos que  $i$  domina;
- ▶ Fitness Bruto  $R(i)$  do indivíduo  $i$ : soma das forças de todos os indivíduos que dominam  $i$  (quanto maior, pior o indivíduo);
- ▶ Densidade  $D(i)$  do indivíduo  $i$ : inverso da distância ao  $k$ -ésimo vizinho mais próximo ( $\sigma_i^k$ ) no espaço de objetivos (leva à exploração de regiões pouco-povoadas):

$$D(i) = \frac{1}{\sigma_i^k + 1}$$



$$F_{\text{SPEA2}}(i) = R(i) + D(i)$$

# Algoritmos Evolutivos

## SPEA2: Cálculo do *Fitness*

$$F_{\text{SPEA2}}(i) = R(i) + D(i)$$

→ Diversidade no Espaço de Objetivos

→ Proximidade da Fronteira de Pareto

Trata as duas exigências em uma única métrica, **que deve ser minimizada.**

# Algoritmos Evolutivos

## SPEA2: Atualização do Arquivo

- ▶ Deve manter o arquivo sempre com o mesmo número de soluções  $N_A$ , definido pelo usuário;
- ▶ Busca manter uma melhor cobertura da fronteira de Pareto, evitando a eliminação de soluções dos extremos da fronteira;
- ▶ É acionado na etapa de inserção das soluções não-dominadas da população no arquivo.

Se  $|\text{arquivo}|$  é inferior a  $N_A$ :

- ▶ Completa o arquivo com os  $N_A - |\text{arquivo}|$  melhores indivíduos dominados (*fitness*);

Se  $|\text{arquivo}|$  é superior a  $N_A$ :

- ▶ Elimina os indivíduos excedentes através de um processo iterativo, que exclui os indivíduos de menor distância aos seus  $k$  vizinhos mais próximos.

# Algoritmos Evolutivos

## Comentários sobre NSGA-II e SPEA2

- ▶ São os dois algoritmos mais utilizados (benchmarks);
- ▶ Ainda são considerados estado-da-arte;
- ▶ São algoritmos custosos:
  - ▶ **NSGA-II:**
    - ▶ Ranking por não dominância;
    - ▶ *Crowding Distance*: ordenação de todos os indivíduos por cada objetivo;
  - ▶ **SPEA2:**
    - ▶ Para cada indivíduo, deve ser calculada a distância a todos os demais indivíduos;
    - ▶ Tais vetores de distâncias devem ser ordenados para obtenção do *k*-ésimo vizinho mais próximo;



# Algoritmos Evolutivos

## Outras Propostas: MOEA/D

- ▶ *Multi-Objective Evolutionary Algorithm Based on Decomposition* (Zhang & Li, 2007):
  - ▶ Decompõe o problema original em vários sub-problemas (permite usar qualquer técnica de decomposição);
  - ▶ Tende a ser menos custoso que NSGA-II e SPEA2;
  - ▶ Vem apresentando ótimos resultados na literatura;
  - ▶ Foi o vencedor da competição de otimização multiobjetivo para problemas sem restrições, no *IEEE Congress on Evolutionary Computation 2009* (CEC'2009).

# Algoritmos Evolutivos

## Outras Propostas: Omni-Optimizer (Deb & Tiwari, 2005)

- ▶ É uma extensão do NSGA-II para tratar tanto problemas de otimização multiobjetivo quanto mono-objetivo;
- ▶ Apresenta mecanismos que se adaptam automaticamente ao tipo de problema sendo tratado;
- ▶ Introduce operadores para manutenção de diversidade também no espaço de variáveis:
  - ▶ Para tratar a questão da multimodalidade;
  - ▶ Modificação no operador de *crowding distance*;

# Algoritmos Evolutivos

## Outras Propostas: cob-aiNet[MO]

- ▶ **cob-aiNet[MO]** – *Concentration-based Artificial Immune Network for Multiobjective Optimization* (Coelho & Von Zuben, 2011):
  - ▶ Proposto para tratar problemas que exigem não só a obtenção de uma boa aproximação da fronteira de Pareto, mas também do conjunto de Pareto;
  - ▶ Baseado no paradigma de Sistemas Imunológicos Artificiais:
    - ▶ Muitos algoritmos baseados neste paradigma possuem boa capacidade de manutenção de diversidade no espaço de variáveis;
  - ▶ Adota a técnica de atribuição de *fitness* do SPEA2:
    - ▶ Mecanismos imuno-inspirados voltados para manutenção de diversidade no espaço de variáveis;

# Conteúdo


---

- ▶ Conceitos Básicos;
- ▶ Algoritmos Clássicos vs. Algoritmos Evolutivos:
- ▶ Casos de Estudo;
- ▶ Tendências e Aplicações;
- ▶ Referências.


# Casos de Estudo

## Problema Deb & Tiwari – Fronteiras de Pareto


- ▶ Problema com dois objetivos e cinco variáveis;
- ▶ Multimodal;
- ▶ Conjunto de Pareto distribuído em regiões separadas e bem definidas;



(a) cob-aiNet[MO]



(b) NSGA-II




(c) omni-optimizer

# Casos de Estudo

Problema Deb & Tiwari – Conjuntos de Pareto

Omni-optimizer




cob-aiNet[MO]


# Casos de Estudo

## Problema ZDT3 – Fronteiras de Pareto


- ▶ Problema com dois objetivos e trinta variáveis;
- ▶ Fronteira de Pareto descontínua.



(a) cob-aiNet[MO]



(b) NSGA-II




(c) omni-optimizer


# Casos de Estudo

## Problema DTLZ2 – Fronteiras de Pareto

- ▶ Pertence à classe de problemas DTLZ:
  - ▶ Escalabilidade do número de objetivos;
- ▶ Fronteira de Pareto não-convexa.



cob-aiNet[MO]



NSGA-II



# Conteúdo

---

- ▶ Conceitos Básicos;
- ▶ Algoritmos Clássicos vs. Algoritmos Evolutivos;
- ▶ Casos de Estudo;
- ▶ Tendências e Aplicações;
- ▶ Referências.


# Tendências

---

- ▶ Inserção de preferências *a priori*;
- ▶ Interatividade;
- ▶ MOEAs capazes de trabalhar com muitos objetivos;
- ▶ MOEAs para otimização robusta;
- ▶ MOEAs para problemas de otimização dinâmica;
- ▶ *Innovization* – melhor compreensão do problema a partir de análise de soluções obtidas por MOEAs;
- ▶ ...

# Exemplos de Aplicações


## Clusterização Multi-Objetivo



Compactação



Conexão



Separação Espacial

HANDL J., KNOWLES J.: *An Evolutionary Approach to Multiobjective Clustering*. In IEEE Transactions on Evolutionary Computation, 11(1), 2007.

RIPON K. S. N., SIDDIQUE M. N. H.: *Evolutionary Multi-Objective Clustering for Overlapping Clusters Detection*. In: Proceedings of the 2009 IEEE Congress on Evolutionary Computation (CEC), 2009.

WANG Y., DANG C., LI H., HAN L., WEI J.: *A Clustering Multi-Objective Evolutionary Algorithm Based on Orthogonal and Uniform Design*. In: Proceedings of the 2009 IEEE Congress on Evolutionary Computation (CEC), 2009.

# Exemplos de Aplicações

## Geração e Distribuição de Energia

### Distribuição de Energia:

IPPOLITO M. G., SANSEVERINO E. R., VUINOVICH F.: *Multiobjective Ant Colony Search Algorithm For Optimal Electrical Distribution System Strategical Planning*. In 2004 IEEE Congress on Evolutionary Computation, 2004.

ABIDO M. A.: *Multiobjective Evolutionary Algorithms for Electric Power Dispatch Problem*. In IEEE Transactions on Evolutionary Computation, 10(3), Jun. 2006.

MENDOZA F., BERNAL-AGUSTÍN J. L., DOMÍNGUEZ-NAVARRO J. A.: *NSGA and SPEA Applied to Multiobjective Design of Power Distribution Systems*. In IEEE Transactions on Power Systems, 21(4), Nov. 2006.

### Controle em Usinas

KIM D. H., JO J. H., LEE H.: *Robust Power Plant Control Using Clonal Selection of Immune Algorithm Based Multiobjective*. In Proceedings of the Fourth International Conference on Hybrid Intelligent Systems, 2004.

# Exemplos de Aplicações

## Telecomunicações

TAGAWA K., KOJIMA N.: *Multi-Objective Optimum Design of DMS Filters Using Robust Engineering and Genetic Algorithm*. In 2006 IEEE Congress on Evolutionary Computation , 2006.

LISBOA A. C., VIEIRA D. A. G., VASCONCELOS J. A. SALDANHA R. R., TAKAHASHI R. H. C.: *Multiobjective Shape Optimization of Broad-Band Reflector Antennas Using the Cone of Efficient Directions Algorithm*. In IEEE Transactions on Magnetics, 42(4), Apr. 2006.

## Design de Sistemas Embarcados

ASCIA G., CATANIA V., DI NUOVO A. G., PALES M., PATTI D.: *A Multiobjective Genetic Fuzzy Approach for Intelligent System-level Exploration in Parameterized VLIW Processor Design*. In 2006 IEEE Congress on Evolutionary Computation , 2006.

SILVA M. V. C., NEDJAH N., MOURELLE N. M.: *Evolutionary IP Assignment for Efficient NoC-Based System Design Using Multi-Objective Optimization*. In: Proceedings of the 2009 IEEE Congress on Evolutionary Computation (CEC), 2009.

# Exemplos de Aplicações

## Posicionamento de Sensores de Sonar

NGATCHOU P.N., FOX W. L. J., EL-SHARKAWI M. A.: *Multiobjective Multistatic Sonar Sensor Placement*. In 2006 IEEE Congress on Evolutionary Computation , 2006.

## Robótica

CAPÍ G.: *A New Method for Simultaneous Evolution of Robot Behaviors based on Multiobjective Evolution*. In Proceedings of the 2006 International Conference on Intelligent Robots and Systems, 2006.

MOSHAIOV A., WITTENBERG A. A.: *Multi-Objective Evolution of Robot Neuro-Controllers*. In: Proceedings of the 2009 IEEE Congress on Evolutionary Computation (CEC), 2009

## Job Shop Scheduling

CHIANG T.-C., FU L.-C.: *Multiobjective Job Shop Scheduling using Genetic Algorithm with Cyclic Fitness Assignment*. In 2006 IEEE Congress on Evolutionary Computation , 2006.

# Exemplos de Aplicações

## Design Industrial

- BENEDETTI A., FARINA M., GOBBI M.: *Evolutionary Multiobjective Industrial Design: The Case of a Racing Car Tire-Suspension System*. In IEEE Transactions on Evolutionary Computation ,10 (3), Jun. 2006.
- ZHANG Q., MAHFOUF M.: *A Modified PSO with a Dynamically Varying Population and Its Application to the Multi-Objective Optimal Design of Alloy Steels*. In: Proceedings of the 2009 IEEE Congress on Evolutionary Computation (CEC), 2009
- SANTOS J. S. S., OLIVEIRA D. B., WANNER E. F., CARRANO E. G., TAKAHASHI R. H. C., SILVA E. J., NETO O. M.: *Designing a Multilayer Microwave Heating Device Using a Multiobjective Genetic Algorithm*. In: Proceedings of the 2009 IEEE Congress on Evolutionary Computation (CEC), 2009

# Conteúdo

---

- ▶ Conceitos Básicos;
- ▶ Algoritmos Clássicos vs. Algoritmos Evolutivos;
- ▶ Casos de Estudo;
- ▶ Tendências e Aplicações;
- ▶ Referências.



# Outras Referências

---

COELLO COELLO, C. A., LAMONT, G. B., VAN VELDHIJZEN, D. A.: *Evolutionary Algorithms for Solving Multi-Objective Problems*, 2nd. Ed., Springer, 2007.

COELLO COELLO C. A.: *Evolutionary Multi-Objective Optimization: A Historical View of the Field*. In IEEE Computational Intelligence Magazine, Feb. 2006.

DEB K.: *Multi-objective Optimization using Evolutionary Algorithms*. John Wiley & Sons, 2001.